

ระบบจำแนกปอดอักเสบจากภาพถ่ายรังสีทรวงอกด้วยโครงข่ายคอนโวลูชัน

Classification system for pneumonia from chest X-ray images using
convolutional neural networks

วีราพงษ์ ทรัพย์สุขศรี , ศุภกิจ จรุงปัญญา , ผศ.ดร.ฉัตรเกล้า เจริญผล

ภาควิชาวิทยาการคอมพิวเตอร์ คณะวิทยาการสารสนเทศ มหาวิทยาลัยมหาสารคาม

บทคัดย่อ

การใช้บุหรี่ไฟฟ้ามีการเพิ่มขึ้นทั่วโลก และเป็นเรื่องที่ต้องการการสังเกตและป้องกัน โดยเฉพาะกับกลุ่มเยาวชนที่มีความเชื่อผิดว่าการสูบบุหรี่ไฟฟ้าไม่อันตรายจริงๆ แม้ว่าไม่มีนิโคติน แต่ก็ยังเป็นประตูนำเส้นทางสู่การเสพติดสารเสพติดอื่นๆ รวมถึงเพิ่มความเสี่ยงต่อโรคปอดอักเสบ ในข้อนี้ผู้พัฒนาเสนอเว็บไซต์ที่ใช้เทคโนโลยี Deep Learning เพื่อวิเคราะห์รูปภาพ X-ray ของปอดเพื่อช่วยในการตรวจสอบโรคปอดอักเสบโดยรวดเร็วและแม่นยำ ลดระยะเวลาในการตรวจและวิเคราะห์ และเพิ่มความสะดวกในทางการแพทย์ เพื่อลดการเสพติดบุหรี่ไฟฟ้าที่สามารถเป็นประตูนำเส้นทางสู่การเสพติดสารเสพติดอื่นๆ ในอนาคต โดยมีวัตถุประสงค์ของโครงการคือการสร้างระบบที่สามารถตรวจสอบโรคปอดอักเสบจากรูปภาพ X-ray ผ่านเว็บไซต์ ทำความเข้าใจหลักการทำงานของโครงข่ายประสาทเทียมแบบคอนโวลูชันและปรับใช้ในการประมวลผลภาพเอกซเรย์ปอด สุดท้ายคือการสร้างแบบจำลองที่ใช้โครงข่ายประสาทเทียมเพื่อจำแนกภาพ X-ray ของปอดที่มีลักษณะปอดอักเสบได้อย่างแม่นยำและรวดเร็ว

คำสำคัญ: โครงข่ายประสาทเทียม

โครงข่ายประสาทเทียมแบบคอนโวลูชัน ปอดอักเสบ ภาพเอกซเรย์ ภาพถ่ายรังสีทรวงอก

1. บทนำ

บุหรี่ไฟฟ้ากำลังเป็นที่นิยมแพร่หลายทั่วโลก รวมถึงในประเทศไทย โดยเฉพาะอย่างยิ่งในกลุ่มเยาวชนที่หลงเชื่อโฆษณาชวนเชื่อว่าการปลอดภัยและไม่มีสารนิโคติน อย่างไรก็ตาม ข้อมูลจากองค์การอนามัยโลก (WHO) และกรมควบคุมโรคของประเทศไทยได้เผยให้เห็นถึงอันตรายที่เพิ่มขึ้นของบุหรี่ไฟฟ้า โดยเฉพาะอย่างยิ่งปัญหาโรคปอดอักเสบที่พบมากขึ้นในผู้ใช้งาน

ในปี 2563 มีรายงานผู้เสียชีวิตจากปอดอักเสบที่เกี่ยวข้องกับการสูบบุหรี่ไฟฟ้าในสหรัฐอเมริกามากกว่า 680 ราย และในประเทศไทยเองก็มีผู้ป่วยโรคปอดอักเสบจากการใช้บุหรี่ไฟฟ้ามากกว่า 100 ราย แม้บุหรี่ไฟฟ้าจะถูกมองว่าเป็นทางเลือกที่ปลอดภัยกว่าบุหรี่แบบดั้งเดิม แต่ความจริงแล้ว บุหรี่ไฟฟ้ามีสารนิโคตินที่ทำให้เสพติดและอาจนำไปสู่การใช้สารเสพติดอื่นๆ ได้ นอกจากนี้ ยังมีงานวิจัยหลายฉบับที่ระบุถึงอันตรายของนิโคตินและสารเคมีอื่นๆ ที่มีอยู่ในบุหรี่ไฟฟ้า ซึ่งอาจส่งผลเสียต่อสุขภาพในระยะยาว

การวินิจฉัยโรคปอดอักเสบจากบุหรีไฟฟ้าทำได้โดยการเอกซเรย์ปอด แต่ต้องอาศัยความเชี่ยวชาญของแพทย์ในการวิเคราะห์ผลเนื่องจากมีผู้ป่วยเพิ่มขึ้นอย่างต่อเนื่อง ทำให้กระบวนการวินิจฉัยใช้เวลานานขึ้นและอาจส่งผลต่อการรักษาที่ล่าช้า

เพื่อแก้ปัญหานี้ เทคโนโลยี Deep learning ซึ่งเป็นปัญญาประดิษฐ์ที่สามารถเรียนรู้และวิเคราะห์ข้อมูลได้คล้ายมนุษย์ กำลังถูกนำมาประยุกต์ใช้ในการพัฒนาเว็บไซต์เพื่อช่วยวินิจฉัยโรคปอดอักเสบจากภาพเอกซเรย์ปอดได้อย่างรวดเร็วและแม่นยำ โดยระบบจะเรียนรู้จากข้อมูลภาพเอกซเรย์ปอดของผู้ป่วยจำนวนมาก เพื่อให้สามารถระบุลักษณะของโรคปอดอักเสบได้อย่างแม่นยำ

2. ทฤษฎีและงานวิจัยที่เกี่ยวข้อง

การปรับปรุงคุณภาพของภาพ

ในการประมวลผลภาพนั้นการปรับปรุงคุณภาพของภาพได้กลายมาเป็นอีกปัจจัยหนึ่งที่มีความสำคัญและช่วยให้การประมวลผลภาพในลำดับต่อไปนั้นทำได้ง่ายขึ้น ภาพดิจิทัลโดยทั่วไปนั้นเกิดจากดิจิทัล จากข้อมูลที่อยู่ในรูปแบบคลื่นให้กลายมาเป็นข้อมูลแบบจำกัด ดังนั้นบ่อยครั้งที่สภาพแวดล้อมต่างๆ ทำให้ภาพที่เราได้มานั้นไม่ได้เหมาะในการนำมาประมวลผลเพื่อให้ได้ผลลัพธ์ที่ดี ดังนั้นการปรับปรุงคุณภาพของภาพก่อนการประมวลผลจึงเป็นสิ่งที่จำเป็น โดยทั่วไปการปรับปรุงคุณภาพของภาพนั้นจะดำเนินการก่อนการประมวลผลภาพจริง หรือบางครั้งจะเรียก


ขั้นตอนนี้ว่า ขั้นตอนการประมวลผลภาพก่อนการประมวลผลจริง (image pre-processing)

การปรับขนาดภาพ (Resizing)

การปรับขนาดภาพเป็นขั้นตอนแรกเพื่อให้ได้ภาพที่มีมิติเท่ากัน (224x224 พิกเซล) ซึ่งเป็นขนาดมาตรฐานที่เหมาะสมกับการประมวลผลโดยโมเดลที่ต้องการข้อมูลที่สอดคล้องกัน ขนาดที่กำหนดนี้ช่วยให้โมเดลสามารถเรียนรู้จากข้อมูลที่เท่ากันทั่วทั้งชุดข้อมูล และยังช่วยลดความจำเป็นสำหรับการจัดการกับภาพที่มีมิติต่างกันในเวลาประมวลผล

การปรับความคมชัดของภาพ (Contrast Adjustment via Equalize Histogram)

การปรับความคมชัดด้วยวิธี equalize_histogram เป็นกระบวนการที่กระจายความเข้มข้นของพิกเซลในภาพให้กระจายตัวอย่างสม่ำเสมอทั่วทั้งภาพ เพื่อเพิ่มความคมชัดและทำให้รายละเอียดของภาพมีความชัดเจนมากขึ้น ขั้นตอนนี้ช่วยเพิ่มประสิทธิภาพของโมเดลในการรับรู้ลักษณะ



สำคัญของข้อมูล.

ภาพก่อนและหลังปรับคอนทราสต์

Normalization

Normalization คือกระบวนการปรับข้อมูลภาพให้อยู่ในช่วงที่ต้องการ ในกรณีนี้คือ

ช่วง 0 ถึง 1 โดยการหารค่าของแต่ละพิกเซลด้วย 255 การทำให้ข้อมูลมีสเกลที่คงที่ช่วยให้การเรียนรู้ของโมเดลเป็นไปอย่างราบรื่นและลดการเบี่ยงเบนของน้ำหนักที่ได้จากการฝึกฝน Image Transformation (การเปลี่ยนแปลงภาพ)

การเปลี่ยนแปลงภาพเป็นวิธีการสร้างความหลากหลายของชุดข้อมูลโดยการใช้การหมุน, การย่อ/ขยาย, การเคลื่อนย้าย หรือการทำเงา ขั้นตอนนี้ช่วยให้โมเดลสามารถรับรู้และเรียนรู้ได้ดีขึ้นจากลักษณะที่มีความหลากหลาย และสามารถปรับตัวได้ดีเมื่อเผชิญกับข้อมูลใหม่ในการประยุกต์ใช้งานจริง

การประมวลผลล่วงหน้าทีวี่วิเคราะห์นี้เป็นส่วนสำคัญที่ช่วยให้โมเดลมีความเสถียรและประสิทธิภาพที่ดีขึ้น ข้อมูลที่ได้รับการปรับปรุงคุณภาพจะนำไปสู่การฝึกฝนที่มีความแม่นยำสูง และสุดท้ายนำไปสู่การพัฒนาโมเดลที่สามารถตอบสนองต่อความต้องการของงานประมวลผลภาพได้จริงโดยเปรียบเทียบค่าใน confusion matrix

Lung Segmentation (การแบ่งส่วนภาพของปอด)

การแบ่งส่วนปอดเป็นกระบวนการในการวิเคราะห์ภาพทางการแพทย์ ซึ่งปอดจะถูกระบุและแยกออกจากโครงสร้างอื่นๆ ในการสแกนภาพทางการแพทย์ เช่น การเอกซเรย์ทรวงอกหรือการสแกน CT นี่เป็นขั้นตอนสำคัญในระบบการวินิจฉัยอัตโนมัติหลายระบบ และมักใช้ในการตรวจหาโรคปอด เช่น ปอดบวม วัณโรค และมะเร็งปอด

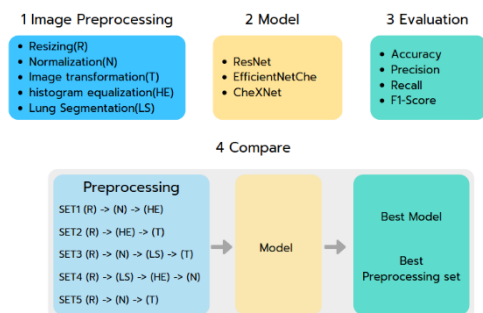
3. ขั้นตอนการดำเนินงาน

ทำการการเก็บข้อมูลตัวอย่างของภาพเอกซเรย์ปอด โดยมีจำนวนของภาพที่ใช้ทั้งหมด (Date set) 5,856 ภาพ แบ่งเป็นชุดข้อมูลฝึก (training set) 5,216 ภาพ และชุดข้อมูลทดสอบ (testing set) 624 ภาพ และชุดข้อมูลตรวจสอบ (validation set) ชุดข้อมูลตรวจสอบ 16 ภาพ โดยแยกตามสภาวะความเสียหายของปอดคือ 1.ปอดอักเสบ (Pneumonia) และ 2. ปอดปกติ (normal)

จากนั้นนำ dataset ไปทำการปรับปรุงคุณภาพโดยรูปแบบในการทำ Pre-Processing นั้นจำทำทั้งหมด 5 รูปแบบได้แก่

1. (Set1)Resize -> Normalization -> Histogram Equalization
2. (Set2)Resize -> Histogram Equalization -> Image Transformation
3. (Set3)Resize -> Normalization -> Lung Segmentation -> Image Transformation
4. (Set4)Resize -> Lung Segmentation -> Histogram Equalization -> Normalization
5. (Set5)Resize -> Normalization -> Image Transformation

จากการทำ Pre-Processing ทั้ง 5 รูปแบบเสร็จสิ้น จะนำไปวัดประสิทธิภาพด้วย CNN โดยใช้ 3 โครงสร้างได้แก่ EfficientNet , CheXNet และ ResNet50



จากนั้นนำทำการทดสอบเพื่อหาว่าโมเดลใดเป็นโมเดลที่เหมาะสม และ วิธีการเตรียมข้อมูลวิธีใดทำให้การฝึกฝนนั้นดีที่สุดด้วยการเปรียบเทียบค่าด้วย Confusion Matrix

4. ผลการทดลอง

หลังจากทำการทดลองด้วย CNN โดยใช้ 3 โครงสร้างได้แก่ EfficientNet , CheXNet และ ResNet50 และการเตรียมข้อมูลทั้ง 5 รูปแบบ นั้นได้ผลการทดลองด้วยค่า Precision, Recall, Accuracy, F1-Score ได้ดังนี้

ตารางที่ 1 Confusion Matrix EfficientNet (set1)

ประเภทของปอด	ผลการทดลอง		
	ปกติ	ปอดอักเสบ	Recall
ปกติ	112	122	$\frac{112}{234} \times 100 = 47\%$
ปอดอักเสบ	3	387	$\frac{387}{390} \times 100 = 99\%$
Precision	$\frac{112}{115} \times 100 = 97\%$	$\frac{387}{509} \times 100 = 76\%$	
Accuracy	$\frac{112 + 387}{234 + 390} \times 100 = 80\%$		
F1 (ปกติ)	$\left(2 \times \frac{(0.97 \times 0.47)}{(0.97 + 0.47)}\right) \times 100 = 64\%$		
F1 (ปอดอักเสบ)	$\left(2 \times \frac{(0.76 \times 0.99)}{(0.76 + 0.99)}\right) \times 100 = 86\%$		

ตารางที่ 2 Confusion Matrix CheXNet (set1)

ประเภทของปอด	ผลการทดลอง		
	ปกติ	ปอดอักเสบ	Recall
ปกติ	142	92	$\frac{142}{234} \times 100 = 61\%$
ปอดอักเสบ	13	377	$\frac{377}{390} \times 100 = 97\%$
Precision	$\frac{142}{155} \times 100 = 92\%$	$\frac{377}{469} \times 100 = 80\%$	
Accuracy	$\frac{142 + 377}{234 + 390} \times 100 = 83\%$		
F1 (ปกติ)	$\left(2 \times \frac{(0.92 \times 0.61)}{(0.92 + 0.61)}\right) \times 100 = 73\%$		
F1 (ปอดอักเสบ)	$\left(2 \times \frac{(0.80 \times 0.97)}{(0.80 + 0.97)}\right) \times 100 = 88\%$		

ตารางที่ 3 Confusion Matrix ResNet50 (set1)

ประเภทของปอด	ผลการทดลอง		
	ปกติ	ปอดอักเสบ	Recall
ปกติ	199	35	$\frac{199}{234} \times 100 = 85\%$
ปอดอักเสบ	47	343	$\frac{343}{390} \times 100 = 88\%$
Precision	$\frac{199}{246} \times 100 = 81\%$	$\frac{343}{378} \times 100 = 91\%$	
Accuracy	$\frac{199 + 343}{234 + 390} \times 100 = 87\%$		
F1 (ปกติ)	$\left(2 \times \frac{(0.81 \times 0.85)}{(0.81 + 0.858)}\right) \times 100 = 83\%$		
F1 (ปอดอักเสบ)	$\left(2 \times \frac{(0.91 \times 0.88)}{(0.91 + 0.88)}\right) \times 100 = 89\%$		

ตารางที่ 4 Confusion Matrix EfficientNet (set2)

ประเภทของปอด	ผลการทดลอง		
	ปกติ	ปอดอักเสบ	Recall
ปกติ	120	106	$\frac{128}{234} \times 100 = 55\%$
ปอดอักเสบ	8	382	$\frac{382}{390} \times 100 = 98\%$
Precision	$\frac{128}{136} \times 100 = 94\%$	$\frac{382}{488} \times 100 = 78\%$	
Accuracy	$\frac{128 + 382}{234 + 390} \times 100 = 82\%$		
F1 (ปกติ)	$\left(2 \times \frac{(0.94 \times 0.55)}{(0.94 + 0.55)}\right) \times 100 = 69\%$		
F1 (ปอดอักเสบ)	$\left(2 \times \frac{(0.78 \times 0.98)}{(0.78 + 0.98)}\right) \times 100 = 87\%$		

ตารางที่ 5 Confusion Matrix CheXNet (set2)

ประเภทของปอด	ผลการทดลอง		
	ปกติ	ปอดอักเสบ	Recall
ปกติ	96	138	$\frac{96}{234} \times 100 = 41\%$
ปอดอักเสบ	5	385	$\frac{385}{390} \times 100 = 99\%$
Precision	$\frac{96}{101} \times 100 = 95\%$	$\frac{385}{523} \times 100 = 74\%$	
Accuracy	$\frac{96 + 385}{234 + 390} \times 100 = 77\%$		
F1 (ปกติ)	$\left(2 \times \frac{(0.95 \times 0.41)}{(0.95 + 0.41)}\right) \times 100 = 57\%$		
F1 (ปอดอักเสบ)	$\left(2 \times \frac{(0.74 \times 0.99)}{(0.74 + 0.99)}\right) \times 100 = 84\%$		

ตารางที่ 6 Confusion Matrix ResNet50 (set2)

ประเภทของปอด	ผลการทดลอง		
	ปกติ	ปอดอักเสบ	Recall
ปกติ	158	76	$\frac{168}{234} \times 100 = 68\%$
ปอดอักเสบ	47	343	$\frac{343}{390} \times 100 = 88\%$
Precision	$\frac{158}{205} \times 100 = 77\%$	$\frac{343}{419} \times 100 = 82\%$	
Accuracy	$\frac{158 + 343}{234 + 390} \times 100 = 80\%$		
F1 (ปกติ)	$\left(2 \times \frac{(0.77 \times 0.68)}{(0.77 + 0.68)}\right) \times 100 = 72\%$		
F1 (ปอดอักเสบ)	$\left(2 \times \frac{(0.82 \times 0.68)}{(0.82 + 0.88)}\right) \times 100 = 85\%$		

ตารางที่ 7 Confusion Matrix EfficientNet (set3)

ประเภทของปอด	ผลการทดลอง		
	ปกติ	ปอดอักเสบ	Recall
ปกติ	89	145	$\frac{89}{234} \times 100 = 38\%$
ปอดอักเสบ	0	390	$\frac{390}{390} \times 100 = 100\%$
Precision	$\frac{89}{89} \times 100 = 100\%$	$\frac{390}{525} \times 100 = 73\%$	
Accuracy	$\frac{89 + 390}{234 + 390} \times 100 = 77\%$		
F1 (ปกติ)	$\left(2 \times \frac{(1 \times 0.38)}{(1 + 0.38)}\right) \times 100 = 55\%$		
F1 (ปอดอักเสบ)	$\left(2 \times \frac{(0.73 \times 1)}{(0.73 + 1)}\right) \times 100 = 84\%$		

ตารางที่ 8 Confusion Matrix CheXNet (set3)

ประเภทของปอด	ผลการทดลอง		
	ปกติ	ปอดอักเสบ	Recall
ปกติ	152	82	$\frac{152}{234} \times 100 = 65\%$
ปอดอักเสบ	10	380	$\frac{380}{390} \times 100 = 97\%$
Precision	$\frac{152}{162} \times 100 = 94\%$	$\frac{380}{462} \times 100 = 82\%$	
Accuracy	$\frac{152 + 380}{234 + 390} \times 100 = 85\%$		
F1 (ปกติ)	$\left(2 \times \frac{(0.94 \times 0.65)}{(0.94 + 0.65)}\right) \times 100 = 77\%$		
F1 (ปอดอักเสบ)	$\left(2 \times \frac{(0.82 \times 0.97)}{(0.82 + 0.97)}\right) \times 100 = 89\%$		

ตารางที่ 12 Confusion Matrix ResNet50 (set4)

ประเภทของปอด	ผลการทดลอง		
	ปกติ	ปอดอักเสบ	ปกติ
ปกติ	0	ปกติ	0
ปอดอักเสบ	0	ปอดอักเสบ	0
Precision	$\frac{0}{0}$	Precision	$\frac{0}{0}$
Accuracy	$\frac{0 + 390}{234 + 390} \times 100 = 63\%$		
F1 (ปกติ)	$\left(2 \times \frac{(0.0 \times 0.63)}{(0.0 + 0.63)}\right)$		
F1 (ปอดอักเสบ)	$\left(2 \times \frac{(0.63 \times 1)}{(0.63 + 1)}\right) \times 100 = 0.77\%$		

ตารางที่ 9 Confusion Matrix ResNet50 (set3)

ประเภทของปอด	ผลการทดลอง		
	ปกติ	ปอดอักเสบ	Recall
ปกติ	144	90	$\frac{144}{234} \times 100 = 62\%$
ปอดอักเสบ	18	372	$\frac{372}{390} \times 100 = 95\%$
Precision	$\frac{144}{162} \times 100 = 89\%$	$\frac{372}{462} \times 100 = 81\%$	
Accuracy	$\frac{144 + 372}{234 + 390} \times 100 = 83\%$		
F1 (ปกติ)	$\left(2 \times \frac{(0.89 \times 0.62)}{(0.89 + 0.62)}\right) \times 100 = 73\%$		
F1 (ปอดอักเสบ)	$\left(2 \times \frac{(0.81 \times 0.95)}{(0.81 + 0.95)}\right) \times 100 = 87\%$		

ตารางที่ 13 Confusion Matrix EfficientNet (set5)

ประเภทของปอด	ผลการทดลอง		
	ปกติ	ปอดอักเสบ	ปกติ
ปกติ	0	ปกติ	0
ปอดอักเสบ	0	ปอดอักเสบ	0
Precision	$\frac{0}{0}$	Precision	$\frac{0}{0}$
Accuracy	$\frac{0 + 390}{234 + 390} \times 100 = 63\%$		
F1 (ปกติ)	$\left(2 \times \frac{(0.0 \times 0.63)}{(0.0 + 0.63)}\right)$		
F1 (ปอดอักเสบ)	$\left(2 \times \frac{(0.63 \times 1)}{(0.63 + 1)}\right) \times 100 = 0.77\%$		

ตารางที่ 10 Confusion Matrix EfficientNet (set4)

ประเภทของปอด	ผลการทดลอง		
	ปกติ	ปอดอักเสบ	Recall
ปกติ	0	234	$\frac{0}{234} \times 100 = 0\%$
ปอดอักเสบ	0	390	$\frac{390}{390} \times 100 = 100\%$
Precision	$\frac{0}{0}$	$\frac{390}{624} \times 100 = 63\%$	
Accuracy	$\frac{0 + 390}{234 + 390} \times 100 = 63\%$		
F1 (ปกติ)	$\left(2 \times \frac{(0.0 \times 0.63)}{(0.0 + 0.63)}\right)$		
F1 (ปอดอักเสบ)	$\left(2 \times \frac{(0.63 \times 1)}{(0.63 + 1)}\right) \times 100 = 0.77\%$		

ตารางที่ 14 Confusion Matrix CheXNet (set5)

ประเภทของปอด	ผลการทดลอง		
	ปกติ	ปอดอักเสบ	Recall
ปกติ	206	28	$\frac{206}{234} \times 100 = 88\%$
ปอดอักเสบ	86	304	$\frac{304}{390} \times 100 = 82\%$
Precision	$\frac{206}{292} \times 100 = 71\%$	$\frac{390}{418} \times 100 = 93\%$	
Accuracy	$\frac{206 + 304}{234 + 390} \times 100 = 82\%$		
F1 (ปกติ)	$\left(2 \times \frac{(0.71 \times 0.88)}{(0.71 + 0.88)}\right) \times 100 = 82\%$		
F1 (ปอดอักเสบ)	$\left(2 \times \frac{(0.92 \times 0.78)}{(0.92 + 0.78)}\right) \times 100 = 84\%$		

ตารางที่ 11 Confusion Matrix CheXNet (set4)

ประเภทของปอด	ผลการทดลอง		
	ปกติ	ปอดอักเสบ	Recall
ปกติ	195	39	$\frac{195}{234} \times 100 = 83\%$
ปอดอักเสบ	27	363	$\frac{363}{390} \times 100 = 93\%$
Precision	$\frac{195}{222} \times 100 = 88\%$	$\frac{363}{402} \times 100 = 90\%$	
Accuracy	$\frac{195 + 363}{234 + 390} \times 100 = 89\%$		
F1 (ปกติ)	$\left(2 \times \frac{(0.88 \times 0.83)}{(0.88 + 0.83)}\right) \times 100 = 86\%$		
F1 (ปอดอักเสบ)	$\left(2 \times \frac{(0.90 \times 0.93)}{(0.90 + 0.93)}\right) \times 100 = 92\%$		

ตารางที่ 15 Confusion Matrix ResNet50 (set5)

ประเภทของปอด	ผลการทดลอง		
	ปกติ	ปอดอักเสบ	ปกติ
ปกติ	0	ปกติ	0
ปอดอักเสบ	0	ปอดอักเสบ	0
Precision	$\frac{0}{0}$	Precision	$\frac{0}{0}$
Accuracy	$\frac{0 + 390}{234 + 390} \times 100 = 63\%$		
F1 (ปกติ)	$\left(2 \times \frac{(0.0 \times 0.63)}{(0.0 + 0.63)}\right)$		
F1 (ปอดอักเสบ)	$\left(2 \times \frac{(0.63 \times 1)}{(0.63 + 1)}\right) \times 100 = 0.77\%$		

5. สรุปผลและข้อเสนอแนะ

โครงงานนี้จะช่วยเพิ่มประสิทธิภาพของการจำแนกภาพถ่ายเอ็กซเรย์ปอด โดยใช้คอมพิวเตอร์มาช่วยในการจำแนกด้วยวิธี Convolutional Neural Network (CNN) และการจัดเก็บข้อมูลในระบบดิจิทัล ซึ่งจะทำให้การจำแนกภาพถ่ายเอ็กซเรย์ปอด มีความแม่นยำมากขึ้น จากการทดลองวัดประสิทธิภาพในการจำแนกภาพถ่ายเอ็กซเรย์ปอด โดยใช้ข้อมูลฝึกฝนทั้งหมด 5,856 ภาพ แบ่งเป็นชุดข้อมูลฝึก (training set) 5,216 ภาพ และชุดข้อมูลทดสอบ (testing set) 624 ภาพ และ (validation set) ชุดข้อมูลตรวจสอบ 16 ภาพ โดยได้นำไปผ่านการฝึกฝนแล้วทดสอบวัดประสิทธิภาพได้ผลดังนี้

ตารางที่ 15 ผลการวัดประสิทธิภาพในการจำแนกภาพเอ็กซเรย์ปอด

	EfficientNet	CheXNet	ResNet50
SET1	79%	83%	86%
SET2	81%	77%	80%
SET3	76%	85%	82%
SET4	62%	89%	62%
SET5	62%	81%	62%

จากการวัดประสิทธิภาพของการฝึกฝนและการเตรียมข้อมูลพบว่าโมเดล CheXNet มีประสิทธิภาพสูงในการเตรียมข้อมูลที่หลากหลายรูปแบบและใน set 4 นั้นมีความถูกต้อง 89% โดยเป็นการทำการเตรียมข้อมูลแบบ Resize -> Lung Segmentation -> Histogram Equalization -> Normalization

และรูปแบบที่ทำให้ค่าความถูกต้องจากค่าเฉลี่ยของความแม่นยำได้ดังนี้ SET1: 82.7% , SET2: 79.3% , SET3: 81.0% , SET4: 71.0% , SET5: 68.3%

ดังนั้น SET1 มีค่าเฉลี่ยความแม่นยำสูงที่สุดที่ 82.7%

ปัญหาและอุปสรรคในการดำเนินงาน

1. ชุดข้อมูลที่ใช้ในการฝึกฝน และทดสอบนั้น ไม่สัมพันธ์กันเพราะส่วนของ validation นั้นน้อยเกินไป
2. รอบในการฝึกฝนของโมเดลต่าง ๆ นั้น ยังน้อยอยู่ ทำให้ค่าความถูกต้องไม่คงที่

ข้อเสนอแนะ

1. ควรใช้ข้อมูลในการฝึกฝนและทดสอบให้มากยิ่งขึ้น
2. เตรียมข้อมูลที่ดีกว่านี้ เพื่อให้ข้อมูลนั้นสมบูรณ์มากยิ่งขึ้น
3. ควรเลือกโมเดลที่มีความทันสมัยเหมือนกันทั้งหมด

เอกสารอ้างอิง

1. ทฤษฎีเบื้องต้นสำหรับการประมวลผลภาพ (Fundamental Theory for Image Processing) : Asst.Prof.Dr.Mahasak Ketcham
2. งานวิจัยของนันทวัฒน์ จูฑี เรื่อง Development of Computer-Aided Diagnosis Algorithm of Lung Nodule from Computed Tomography Images การพัฒนัลกอริทึมคอมพิวเตอร์ช่วยวินิจฉัยก้อนในปอดจากภาพถ่ายเอกซเรย์

- คอมพิวเตอร์ (<https://i101.tci-thaijo.org/index.php/SRIMEDJ/article/download/141463/104824/>)
3. ความรู้ทางการแพทย์ ก้อนในปอดของปอดปกติ วีรินนา ถนอมเกียรติ พ.บ. (2546) พญ. สุวพันธ์ นนทะสุด (2550) รศ.นพ.วีรพท์ ขวนวิสุทธิ พบ.(2542)
 4. A. Paisal และ T. Kasetkasem (อนล โพหาศ และ อีรศักร์ เกษตรเกษม) การคัดแยกเมล็ดพันธุ์ถั่วในถั่วเขียว โดยการวิเคราะห์ภาพถ่าย (Separation the mingling varieties of the mungbean seeds by image processing)
 5. Identity Mappings in Deep Residual Networks (<https://arxiv.org/abs/1603.05027>) (CVPR 2016)
 6. Deep Learning using Transfer Learning - Python Code for ResNet50
 7. Keras API reference / Keras Applications (<https://keras.io/api/>)
 8. L. Bottou. Large-Scale Machine Learning with Stochastic Gradient Descent, pages 177-186. Physica-Verlag HD, Heidelberg, 2010.
 9. Y. Boykov. Fast approximate energy minimization via graph cuts, 1999.
 10. K. Kawattikul and P. Chomphuwiset. Simple text detection in document images using classification-based techniques. Proceedings of the IEEE
 11. A. A. Nath. Image processing for the analysis of images. IEEE Transactions on Systems, Man, and Cybernetics, IEEE Transactions on Systems, Man and Cybernetics, 9(1):62-66, Jan 1979.
 12. การจำแนกภาพขวดแบบแช่เปิดด้วยโครงข่ายประสาทเทียมแบบคอนโวลูชัน, ศุภณัฐ จินตวัฒน์สกุล, 2562
 13. CheXNet: Radiologist-Level Pneumonia Detection on Chest X-Rays with Deep Learning , 2017